



Prédiction des accidents maritimes

Analyse spatiale et temporelle par Random Forest

Auteurs :

Axel Archambeault

Ashley Roo

Encadrant :

M. Salmon

Table des matières

1	Introduction	1
2	Données	2
2.1	Sources des données	2
2.2	Nettoyage et prétraitement	2
2.3	Structure des données finales	2
3	Analyse exploratoire	3
3.1	Évolution temporelle	3
3.2	Distribution spatiale	3
3.3	Facteurs influents	3
4	Modélisation	4
4.1	Approche retenue	4
4.2	Random Forest - Régression	4
4.3	Random Forest - Classification des tendances	4
4.3.1	Validation du modèle	4
4.3.2	Importance des variables	4
5	Résultats	5
5.1	Carte des prédictions	5
5.2	Carte des erreurs	5
5.3	Carte des zones à risque	5
5.4	Carte des tendances	6
6	Améliorations et perspectives	7
6.1	Limites du modèle	7
6.2	Améliorations possibles	7
7	Conclusion	8
	Sources	9

1 Introduction

A compléter

2 Données

2.1 Sources des données

A compléter

- **Accidents maritimes** : 44 097 enregistrements d'accidents en Europe entre 2011 et 2025. Chaque enregistrement contient la localisation (latitude, longitude), la date, l'heure, la gravité, le type de bateau, le port, etc.
- **Densité de trafic AIS** : Données de densité de navigation (Automatic Identification System) pour la période 2017-2021, fournissant l'intensité du trafic maritime par zone.
- **Flotte mondiale** : Évolution du nombre de navires par type (cargo, pétrolier, vraquier, etc.) et par année entre 2011 et 2026.

Résumé des données :

- **Accidents** : 44 097 lignes (2011-2025)
- **Densité AIS** : 2017-2021
- **Flotte mondiale** : 2011-2026
- **Zones** : Grille de $1.5^\circ \times 1.5^\circ$

2.2 Nettoyage et prétraitement

Les données ont subi plusieurs étapes de nettoyage :

1. **Suppression des valeurs manquantes** : Les lignes sans latitude, longitude ou année ont été écartées.
2. **Standardisation des coordonnées** : Conversion des coordonnées en degrés décimaux.
3. **Assignation des accidents à des zones** : Chaque accident a été associé à une zone de grille de $1.5^\circ \times 1.5^\circ$.
4. **Création de variables temporelles** : Lags (1, 2, 3 ans), moyennes mobiles (3, 5 ans), évolution récente.
5. **Fusion avec la flotte et la densité** : Intégration des données de densité AIS et de flotte mondiale.

2.3 Structure des données finales

Le jeu de données final est organisé par zone et par année, avec les variables suivantes :

- **Cible (régression)** : Nombre d'accidents par zone et par année
- **Cible (classification)** : Tendance (5 classes)
- **Features** : Année, densité moyenne, densité max, nombre de navires, lags (1,2,3), moyennes mobiles (3,5), évolution récente

3 Analyse exploratoire

3.1 Évolution temporelle

L'analyse des accidents par année révèle une tendance en trois phases :

- **2011-2015** : Forte augmentation des accidents (de 1 269 à 3 510)
- **2015-2019** : Plateau autour de 3 500 accidents par an
- **2019-2025** : Diminution progressive (3 536 à 2 200)

3.2 Distribution spatiale

Les accidents sont concentrés dans certaines zones stratégiques : Manche, Méditerranée, Atlantique nord. Une carte de chaleur (heatmap) met en évidence ces zones à forte densité d'accidents.

3.3 Facteurs influents

L'analyse des variables montre que :

- Les accidents sont plus fréquents en été et en automne.
- Les cargos et les pétroliers sont les types de bateaux les plus impliqués.
- Les ports majeurs (Rotterdam, Anvers, Hambourg) concentrent un grand nombre d'accidents.

4 Modélisation

4.1 Approche retenue

Deux modèles Random Forest ont été développés :

1. **Régression** : Prédiction du nombre exact d'accidents par zone et par année.
2. **Classification** : Prédiction directe de la tendance (5 classes).

4.2 Random Forest - Régression

Le modèle de régression utilise les paramètres suivants :

- **Features** : densité moyenne, densité médiane, densité max, densité std, nombre de mesures, référence historique
- **Entraînement** : 2017-2022
- **Validation** : 2023-2025
- **Prédiction** : 2026-2030

4.3 Random Forest - Classification des tendances

Le modèle de classification prédit directement la tendance en 5 classes :

- Classe 0 : Forte diminution ($< -30\%$)
- Classe 1 : Faible diminution (-30% à -10%)
- Classe 2 : Stable (-10% à $+10\%$)
- Classe 3 : Faible augmentation ($+10\%$ à $+30\%$)
- Classe 4 : Forte augmentation ($> +30\%$)

4.3.1 Validation du modèle

Le modèle est validé sur la période 2023-2025 :

- **Accuracy** : 0.75 (75%)
- **Matrice de confusion** : Visualisation des erreurs par classe

4.3.2 Importance des variables


Les variables les plus importantes sont :

1. Moyenne 5 ans
2. Densité moyenne
3. Évolution récente
4. Nombre de navires
5. Lags (1, 2, 3)

5 Résultats

5.1 Carte des prédictions

La carte des prédictions (2023-2030) permet de visualiser l'évolution des accidents par zone. Un curseur temporel permet de naviguer année par année.




Carte des prédictions

Carte des prédictions (2023-2030)

5.2 Carte des erreurs

La carte des erreurs (2023-2025) montre où le modèle est fiable ou non. Les zones en vert indiquent une bonne précision, celles en rouge une forte erreur.



Carte des erreurs

Carte des erreurs du modèle

5.3 Carte des zones à risque

La carte des zones à risque identifie les zones où une augmentation significative des accidents est attendue.




Carte des zones à risque

Carte des zones à risque (2026-2030)

5.4 Carte des tendances

La carte des tendances prédites (2023-2030) visualise les 5 classes de tendance pour chaque zone.



Carte des tendances

Carte des tendances prédites (2023-2030)

6 Améliorations et perspectives

6.1 Limites du modèle

Plusieurs limites ont été identifiées :

- **Données limitées** : Seulement 15 années de données disponibles.
- **Résolution spatiale** : Grille de $1.5^\circ \times 1.5^\circ$ (environ 150 km), trop large pour une analyse fine.
- **Facteurs externes** : Non pris en compte (météo, régulations, nouvelles technologies).
- **Extrapolation** : La densité AIS s'arrête en 2021, obligeant à utiliser des valeurs constantes pour les années futures.

6.2 Améliorations possibles

Plusieurs pistes d'amélioration sont envisageables :

1. **Modèles plus complexes** : XGBoost, LSTM (réseaux de neurones pour séries temporelles).
2. **Résolution plus fine** : Grille de $0.5^\circ \times 0.5^\circ$.
3. **Nouvelles variables** : Données météo, courants marins, densité portuaire.
4. **Interface interactive** : Développement d'un tableau de bord Streamlit.
5. **Mise à jour des données** : Intégration des données AIS plus récentes.

7 Conclusion

Ce projet a permis de développer un outil de prédiction des accidents maritimes basé sur un modèle Random Forest, combinant des données d'accidents historiques, de densité de trafic AIS et de flotte mondiale.

Les principaux résultats sont les suivants :

- Une tendance générale à la baisse des accidents depuis 2019.
- L'identification de zones à risque où une augmentation est attendue.
- Un modèle de classification des tendances avec une accuracy de 75% sur 2023-2025.
- Des cartes interactives permettant une visualisation intuitive des prédictions.

Les perspectives d'amélioration sont nombreuses : utilisation de modèles plus complexes, résolution spatiale plus fine, intégration de nouvelles variables. Ce projet constitue une base solide pour des travaux futurs sur la sécurité maritime et la prévention des accidents.

Sources

Données

- [1] EUROPEAN MARITIME SAFETY AGENCY (EMSA). *Maritime Accident Database*. Disponible à l'adresse : <https://www.emsa.europa.eu/>.

Bibliographie

- [2] BREIMAN, L. (2001). *Random Forests*. Machine Learning, 45(1), 5-32.
- [2] JAMES, G., WITTEN, D., HASTIE, T., & TIBSHIRANI, R. (2013). *An Introduction to Statistical Learning*. Springer.

Outils et bibliothèques

- [4] SCIKIT-LEARN. *Random Forest Classifier and Regressor*. Disponible à l'adresse : <https://scikit-learn.org/>.
- [4] FOLIUM. *Interactive Maps with Python*. Disponible à l'adresse : <https://python-visualization.github.io/folium/>.